CUAI Research MM 1팀

2026-04-28

발표자 : 신승현

VLA Token Pruning Methods

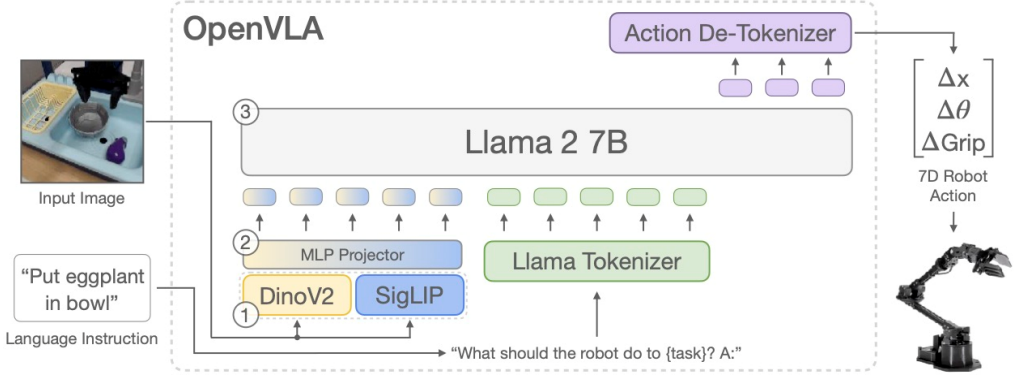

7B parameters 오픈소스 VLA

Backbone: Llama 2 7B

Vision Encoder

- DINOv2 - 공간 추론
- SigLIP - high level image 이해

Action Output

- 로봇의 7D action을 language model의 text token처럼 처리한다
- 각 차원을 256개의 Bin으로 나누어 연속적인 동작을 discrete하게 처리한다. Llama의 tokenizer는 special token을 100개만 예약하여 가장 사용 빈도가 낮은 token 256개를 찾아내어 로봇의 동작을 나타내는 새로운 action token으로 대체한다.

Research Gap : Token Pruning의 필요성

- 7D action을 매 step 예측해야 하므로 LLM이 처리해야 할 sequence의 길이가 길어짐
- input vision token중 action token에 대한 contribution이 낮은 token을 제거해 연산량을 줄임

VLA Token Pruning Methods – VLA Cache

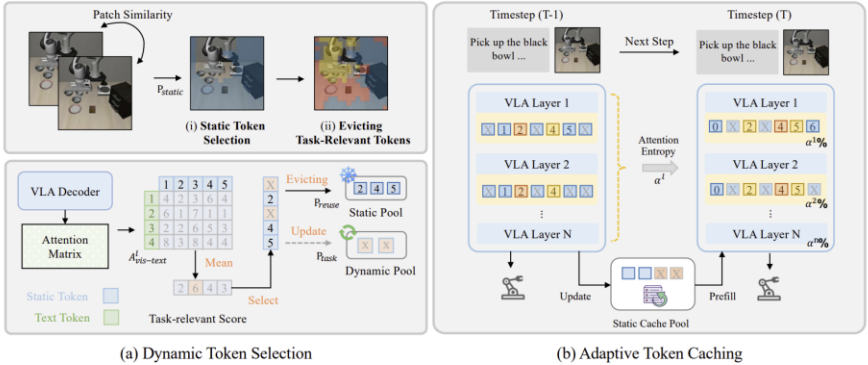

Figure 2: **VLA-Cache** accelerates the VLA's language decoding process across timesteps via the following two steps: (a) *Dynamic Token Selection* reuses static tokens across frames while preserving task-relevant ones; (b) *Adaptive Token Caching* dynamically adjusts reuse ratios per decoder layer based on attention patterns.

- Robot의 배경이나 특정 object는 여러 frame동안 거의 변하지 않음

- 기존 VLA는 매 frame 모든 visual token을 처음부터 다시 계산해 latency가 발생함

- 인접한 frame 간 변화가 적은 static token은 이전 step 결과를 reuse하고 변화가 큰 부분만 새로 계산

VLA Token Pruning Methods – VLA Cache

Dynamic Token Selection

- Static Token Identification - frame 간 patch cosine similarity를 측정해 변화가 거의 없는 token을 식별
- KV Cache - 식별된 static token은 transformer의 KV chache을 그대로 유지

Task-Relevant Filtering

- 시각적으로 변하지 않아도 gripper 주변이나 목표 object는 action 결정에 매우 중요
- decoder의 attention score을 분석해, 모델이 중요하게 여기는 token은 static이더라도 새로 계산

Layer Adaptive Strategy

- decoder low layer는 분산된 정보 저장, high layer는특정 정보에 집중하는 특성
- 각 layer의 attention entrophy에 따라 token reuse 배율을 dynamic하기 조절

VLA Token Pruning Methods – EfficientVLA

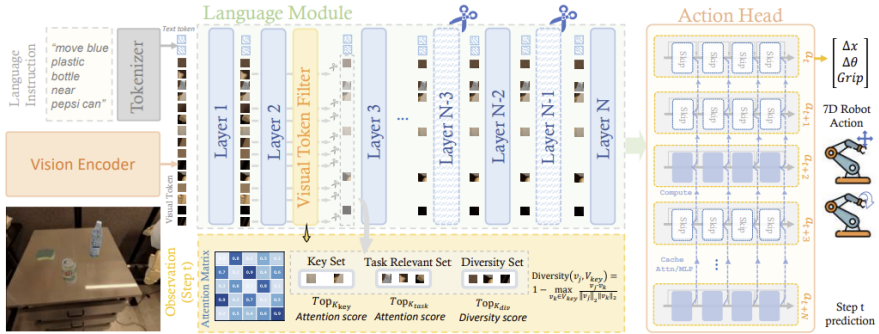

Figure 2: Overview of the **EfficientVLA** framework, our training-free, structured approach to accelerate Diffusion-based VLAs. It employs: (1) pruning of redundant language module layers; (2) VLA task-aware visual token selection balancing task relevance and informational diversity; and (3) temporal caching of intermediate featuresin the diffusion action head.

LM Layer Pruning:

- Transformer layer 중 일부는 input ≈ output → useless layer
- 따라서 중요도 낮은 layer는 제거

Vision Module: Task-aware Token Pruning:

- vision to instruction attention → 각 토큰 별 task relevance score 계산
- 이 중 상위 K개의 Key Set 선택(4~8개) & 최종 token 예산(56, 112개)
- Key Set = augmentation tokens(나머지 상위 K개의 task relevance token, Diversity Set(50%): key set 안의 각 토큰과 max sim인 token들에 대해 1 - max cos로 top k token 선별)

VLA Token Pruning Methods – EfficientVLA

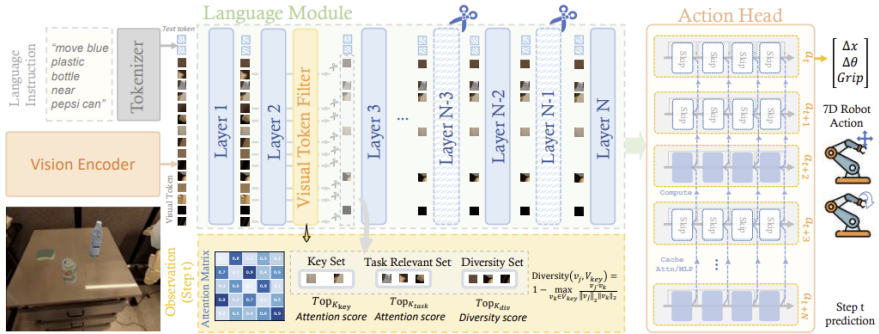

Figure 2: Overview of the **EfficientVLA** framework, our training-free, structured approach to accelerate Diffusion-based VLAs. It employs: (1) pruning of redundant language module layers; (2) VLA task-aware visual token selection balancing task relevance and informational diversity; and (3) temporal caching of intermediate featuresin the diffusion action head.

Action Module: Diffusion Caching

- diffusion은 step마다 동일한 연산 반복 → feature 거의 안변함
- 따라서 일정 간격 N마다만 계산하고 나머지 cache 재사용

VLA Token Pruning Methods – VLAPruner

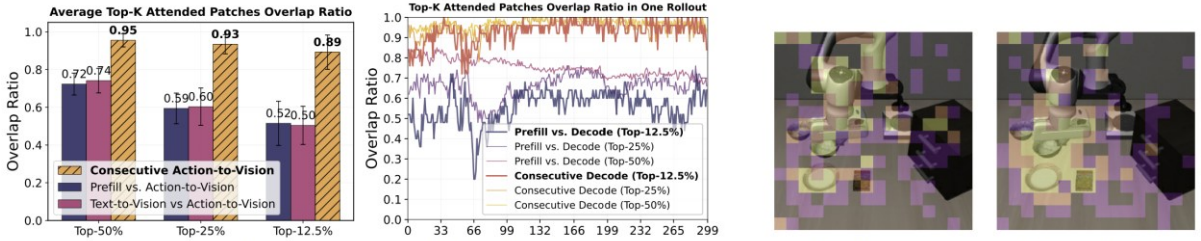

(a) Average Overlap *(b)* Overlap Ratio Trend *(c)* Prefill Attention *(d)* Decode Attention

Figure 2. **Distinct attention patterns across VLA inference. (a–b)** Overlap ratios of Top-k attended patches: (i) between vision–language prefill and action decode (Top-$k(\mathcal{S}_{\text{vl}})$ vs. Top-$k(\mathcal{S}_{\text{act}})$), and (ii) between consecutive action-decode timesteps (Top-$k(\mathcal{S}^{t}_{\text{act}})$ vs. Top-$k(\mathcal{S}^{t-1}_{\text{act}})$). We show average values (a) and a representative rollout (b). **(c–d)** Visualization of prefill (c) and action decode (d) attention over the same frame; top 12.5% (yellow), 25% (orange), and 50% (purple) patches are overlaid. Prefilling shows broad semantic coverage, while action decoding is locally focused. The results reveal VLA model's **dual-system nature** that token pruning must handle.

Action-Guided Token Pruning

- LLM deocder cross attention map을 분석해 모델이 action token을 생성할 때, 어떤 vision patch을 주로 참고하는지 파악
- attention이 낮은 token은 task와 무관한 것으로 간주하고 연산에서 제외

Vision-Language Prefill Attention

- text와 image 사이의 semantic 관련성 파악

Action Decode Attention

- robot의 구체적인 action에 필요한 low-level 정보 보존
- 무엇이 중요한지를 넘어 어떻게 움직여야 하는지 집중하는 token

VLA Token Pruning Methods – VLAPruner

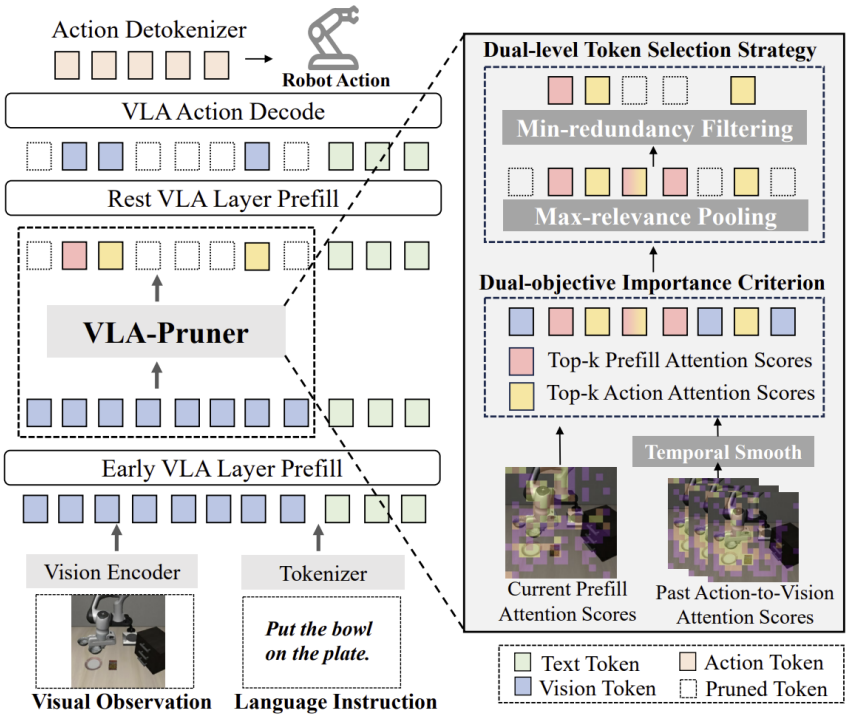

Figure 3. **Overview of VLA-Pruner** (illustrated with budget k=3). It unites tokens salient at semantic or action level, then filters redundancy to obtain a compact subset that preserves essential information for both semantic understanding and action execution.

Spatial-Temporal Token Fusion

- static background token은 하나로 fusion해 정보를 압축
- Gripper나 object와 같이 움직임이 있는 부분은 token을 유지

Problem

기존 VLA acceleration / pruning 방법들은 대부분 다음 질문에 집중한다.

=> Which visual tokens are important?

- VLA-Pruner는 semantic prefill attention과 action decode attention을 함께 써서 dual-level selection을 수행하고, VLA-Cache는 visual similarity와 task relevance filtering을 결합한다. 하지만 실제 closed-loop VLA inference에서는 token selection과 별개로 더 근본적인 질문이 있다.

=> At the current timestep, how many visual tokens are actually needed to preserve correct action generation?

- 이 질문은 기존 방법들에서 직접적으로 다뤄지지 않는다.
- 현재 step의 control state가 쉬운지 어려운지, action decision이 안정적인지, 불안정한지에 따라 필요한 visual evidence의 양은 달라질 수 있다. 따라서 fixed token budget은 suboptimal할 수 있다.

Our Direction

Our Direction: Adaptive Token Budgeting for VLA

- 현재 timestep에서 안정적인 action 생성을 위해 visual token이 몇 개나 필요한가?'

[핵심 가정]

- 쉬운 / 안정적인 control state에서는 적은 visual token으로도 충분하고, 어렵거나 불확실한 state에서는 더 많은 visual evidence가 필요하다.

[방법 개요]

1. 현재 action uncertainty 추정

- action-token distribution의 entropy 또는 margin 사용 & 필요하면 EMA로 temporal smoothing 적용

2. uncertainty를 token budget으로 변환

- low uncertainty → 더 공격적인 pruning & high uncertainty → 더 보수적인 pruning

3. 정해진 budget 안에서 top-K visual token 선택

- attention-based selector 또는 similarity-based selector 재사용 가능 & novelty는 token scoring 자체보다 dynamic budget allocation에 있음

기대 효과

- Closed-loop VLA inference에서 action accuracy를 유지하면서 computation을 줄이는 adaptive token pruning